

**KLASIFIKASI CITRA LESI PRA-KANKER SERVIKS BERDASARKAN HSV
STATISTIK DAN COLOR DOMINAN MENGGUNAKAN XGBOOST CLASSIFIER**

UJIAN AKHIR SEMESTER

Mata Kuliah Citra Biomedik



OLEH:

Revidya Aprilla Sandiva (0901128227054)

Wanda Hamidah (09011282227052)

M. Razhel Miroza (09011282227091)

Rafki Sahasika Riyuda (09011282227007)

Zahra Maharani Putri (09011282327105)

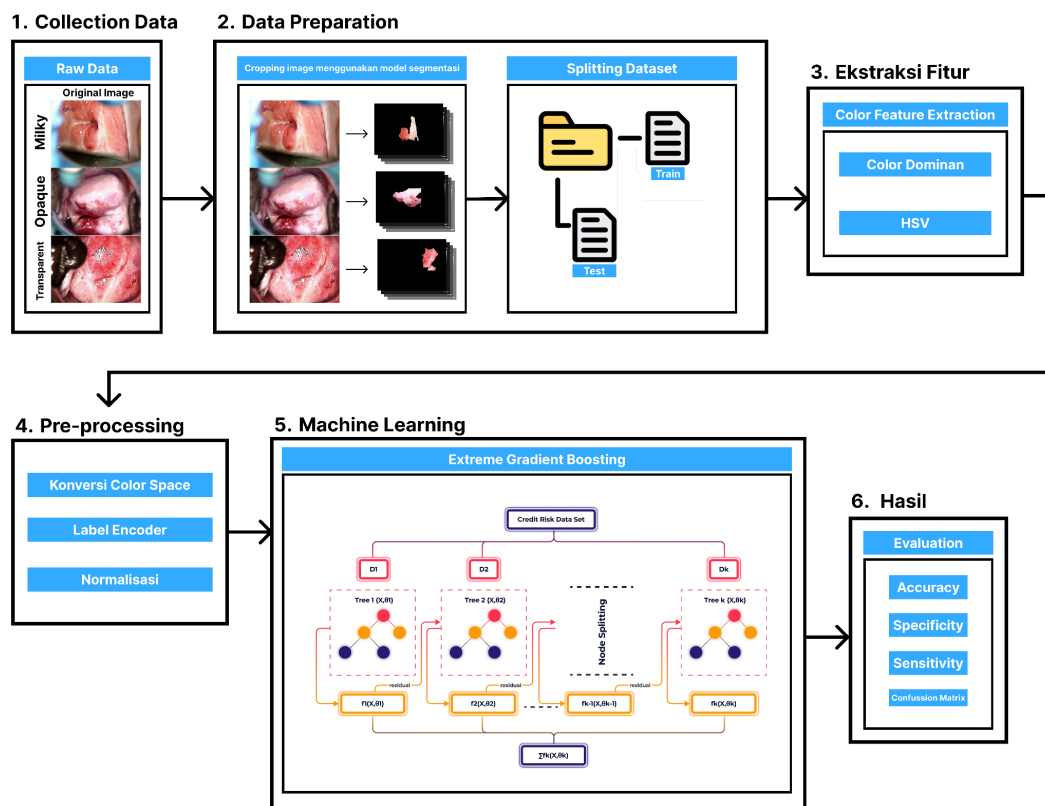
JURUSAN SISTEM KOMPUTER

FAKULTAS ILMU KOMPUTER

UNIVERSITAS SRIWIJAYA



2025

1. Metodologi Penelitian



Penelitian ini menerapkan alur kerja sistematis untuk mengklasifikasikan citra lesi serviks ke dalam tiga kelas, yaitu *Milky*, *Opaque*, dan *Transparent*. Proyek dimulai dari penggunaan citra ROI hasil segmentasi lesi yang telah tersedia, kemudian data disusun berdasarkan struktur case dan dibagi menjadi data latih dan data uji dengan pendekatan *case-based splitting* untuk mencegah kebocoran data antar pasien. Setiap citra diubah ukurannya menjadi 224×224 piksel dan dikonversi ke ruang warna HSV untuk keperluan analisis warna. Ekstraksi fitur dilakukan dengan menggabungkan statistik warna HSV berupa nilai rata-rata dan standar deviasi pada kanal *Hue*, *Saturation*, dan *Value*, serta fitur warna dominan yang diperoleh melalui K-Means clustering dengan $k = 3$ pada ruang warna HSV. Seluruh fitur numerik tersebut digunakan sebagai masukan untuk melatih model klasifikasi *Extreme Gradient Boosting* (XGBoost). Kinerja model kemudian dievaluasi menggunakan metrik *accuracy*, *specificity*, *sensitivity*, berdasarkan hasil prediksi pada data uji untuk menilai kemampuan sistem dalam membedakan karakteristik visual citra lesi serviks.

2. Pengumpulan Data

Transparent	Milky	Opaque
46	26	50
		

Tahap ini merupakan fase awal dimana data gambar lesi serviks dikumpulkan dari berbagai sumber medis melalui pemeriksaan kolposkopi atau metode pencitraan serviks lainnya. Berdasarkan kode yang ada, dataset terdiri dari tiga kategori utama: *milky*, *opaque*, dan *transparent*. Setiap kategori merepresentasikan tingkat keparahan atau karakteristik visual dari lesi pada jaringan serviks yang mengindikasikan tahapan perkembangan sel abnormal atau lesi pre-kanker. Data disimpan dalam struktur folder hierarkis dimana setiap kelas memiliki subfolder bernama "Case" (seperti Case 090, Case 091, dst) yang berisi kumpulan gambar dari pasien atau kondisi tertentu. Struktur organisasi ini penting untuk memastikan data dapat dikelola dengan baik dan memudahkan proses analisis berbasis kasus (case-based analysis). Gambar-gambar yang dikumpulkan merupakan citra medis dengan format standar seperti JPG yang menampilkan kondisi jaringan serviks dari berbagai sudut, kondisi pencahayaan, dan tahapan pemeriksaan kolposkopi.



3. Persiapan Data

Segmentasi Lesi menggunakan YOLO

Tahap persiapan data dimulai dengan proses segmentasi otomatis menggunakan model YOLO (*You Only Look Once*) yang telah dilatih sebelumnya. Kode memuat model dari file *best.pt* yang merupakan hasil training YOLO untuk mendeteksi dan mensegmentasi area lesi pada gambar serviks. Proses ini sangat krusial karena dalam gambar medis serviks hasil kolposkopi, tidak semua area relevan untuk analisis - hanya bagian yang mengalami perubahan jaringan atau lesi yang perlu diekstraksi. Area normal seperti jaringan serviks yang

sehat, background hitam dari alat medis, atau artefak lainnya harus dipisahkan. Model YOLO melakukan prediksi pada setiap gambar dengan *confidence threshold* yang telah ditentukan (0.05 untuk deteksi awal, kemudian difilter dengan 0.15 untuk memastikan kualitas deteksi yang lebih tinggi). Hasil segmentasi berupa mask binary yang menandai piksel mana yang termasuk area lesi dan mana yang bukan.

Ekstraksi Lesi (Hanya Lesion)

Raw Data	Data Baru
	

Setelah segmentasi, melakukan ekstraksi lesi murni dengan cara membuat canvas hitam berukuran sama dengan gambar asli, kemudian hanya menyalin piksel-piksel yang berada dalam area mask hasil segmentasi YOLO. Proses ini menghasilkan gambar baru dimana background sepenuhnya hitam (nilai piksel 0,0,0) dan hanya area lesi serviks yang mempertahankan warna aslinya. Teknik ini penting untuk memfokuskan analisis warna hanya pada area yang relevan secara medis, menghilangkan noise dari background, instrumen medis, cairan tubuh, atau jaringan serviks normal yang tidak terpengaruh lesi. Dalam konteks kanker serviks, isolasi area lesi ini memungkinkan analisis yang lebih akurat terhadap perubahan warna jaringan yang mengindikasikan displasia atau transformasi sel abnormal. Output disimpan dalam folder *lesion_only* mencantumkan confidence score dan index objek untuk traceability dan audit medis.

Splitting Dataset

Label	Train		Test	
	Total Per-Case	Total Gambar	Total Per-Case	Total Gambar
Transparent	37	101	9	15
Milky	20	57	6	24
Opaque	40	145	10	44
Total:	97	303	25	83

Data kemudian dibagi menjadi dua subset: train dan test. Pembagian ini mengikuti prinsip *case-based splitting* dimana folder-folder Case dibagi secara acak dengan proporsi 80:20 untuk data latih dan data ujinya. Metode *case-based splitting* sangat penting dalam konteks medis karena memastikan bahwa gambar-gambar dari pasien yang sama tidak tersebar di kedua subset, yang bisa menyebabkan data bocor dan overestimasi performa model. Dalam kasus kanker serviks, satu pasien bisa memiliki multiple gambar dari berbagai sudut atau tahapan pemeriksaan yang sama, sehingga penting untuk memastikan integritas evaluasi. *Stratified splitting* juga diterapkan untuk memastikan distribusi kelas tetap seimbang di kedua subset, sehingga model tidak bias terhadap tingkat keparahan lesi tertentu yang mungkin lebih dominan dalam dataset.

4. Pra-Pemrosesan

1) Resizing

Proses resizing dilakukan untuk menyeragamkan ukuran seluruh citra sebelum tahap ekstraksi fitur. Pada proyek ini, setiap citra ROI lesi diubah ukurannya menjadi 224×224 piksel agar seluruh data memiliki dimensi yang konsisten. Langkah ini memudahkan proses pemrosesan citra dan memastikan bahwa ekstraksi fitur warna HSV dan warna dominan dilakukan pada representasi citra yang sebanding. Resizing juga membantu menekan beban komputasi tanpa menghilangkan informasi warna utama yang menjadi fokus analisis dalam klasifikasi lesi serviks.

2) Konversi Color Space

Secara umum, citra digital disimpan dalam ruang warna **RGB (Red, Green, Blue)**. Namun, untuk keperluan analisis warna, ruang warna **HSV (Hue, Saturation, Value)** lebih sering digunakan karena mampu merepresentasikan warna secara lebih intuitif dan mendekati persepsi visual manusia. Oleh karena itu, nilai RGB perlu dikonversi terlebih dahulu ke ruang warna HSV [1]. Langkah konversi RGB ke HSV dilakukan sebagai berikut.

Pertama, ditentukan nilai maksimum dan minimum dari komponen warna RGB:

$$\begin{aligned} M &= \max (R, G, B) \\ N &= \min (R, G, B) \end{aligned} \quad (1)$$

Nilai M merepresentasikan intensitas warna tertinggi, sedangkan N merepresentasikan intensitas terendah dalam satu piksel.

Komponen Hue (H) menunjukkan jenis warna dominan dan dihitung berdasarkan selisih antara nilai maksimum dan minimum RGB. Perhitungan Hue bersifat kondisional sebagai berikut:

$$H = \begin{cases} 0^\circ & (M=N) \\ 60^\circ \times \left(\frac{g-b}{M-N} + 360 \right) & (M=r \text{ and } g < b) \\ 60^\circ \times \left(\frac{b-r}{M-N} + 120 \right) & (M=g) \\ 60^\circ \times \left(\frac{b-r}{M-N} + 240 \right) & (M=b) \end{cases} \quad (2)$$

- Jika $M=N$, maka warna bersifat achromatic (abu-abu), sehingga nilai Hue ditetapkan sebesar 0.
- Jika $M=R$, maka Hue dihitung berdasarkan selisih antara komponen hijau dan biru. Jika $M=G$, maka Hue dihitung berdasarkan selisih antara komponen biru dan merah dengan penyesuaian sudut.
- Jika $M=B$, maka Hue dihitung berdasarkan selisih antara komponen merah dan hijau dengan penyesuaian sudut.

Penyesuaian sudut sebesar 120° dan 240° dilakukan untuk memastikan nilai Hue berada pada rentang 0° hingga 360°

Komponen Saturation (S) merepresentasikan tingkat kejenuhan warna dan dihitung sebagai selisih antara nilai maksimum dan minimum RGB:

$$S = M - N \quad (3)$$

Semakin besar nilai Saturation, semakin kuat atau jenuh warna tersebut. Sebaliknya, nilai Saturation mendekati nol menunjukkan warna mendekati abu-abu.

Komponen Value (V) merepresentasikan tingkat kecerahan warna dan ditentukan langsung dari nilai maksimum RGB:

$$V = M \quad (4)$$

Nilai Value yang tinggi menunjukkan warna yang lebih terang, sedangkan nilai yang rendah menunjukkan warna yang lebih gelap.

Dengan demikian, konversi dari ruang warna RGB ke HSV memungkinkan pemisahan informasi warna (Hue), kejenuhan (Saturation), dan kecerahan (Value), sehingga lebih efektif digunakan dalam proses ekstraksi fitur dan analisis citra berbasis warna.

3) Label Encoding

Di proyek ini, label kelas masih berbentuk teks, yaitu milky, opaque, dan transparent. Model XGBoost tidak dapat memproses label kategorikal dalam bentuk string, sehingga sistem mengubah label tersebut menjadi representasi numerik menggunakan teknik label encoding. Setiap kelas dipetakan ke bilangan bulat yang unik agar dapat digunakan sebagai target pada proses pelatihan dan evaluasi model. Proses ini dilakukan setelah pembagian data latih dan data uji, sehingga konsistensi label tetap terjaga pada seluruh tahapan eksperimen.

4) Normalisasi

Normalisasi fitur dilakukan untuk menyamakan skala seluruh fitur numerik sebelum proses pelatihan model. Pada data ini, setiap fitur warna memiliki rentang nilai yang berbeda, misalnya kanal Hue, Saturation, dan Value, serta fitur warna dominan hasil clustering. Jika fitur tidak dinormalisasi, fitur dengan rentang nilai besar akan lebih berpengaruh dan dapat

mengganggu proses pembelajaran XGBoost. Oleh karena itu, sistem menerapkan standardization menggunakan StandardScaler agar setiap fitur memiliki distribusi yang sebanding. Hasil normalisasi menghasilkan fitur dengan rata rata mendekati 0 dan standar deviasi mendekati 1, sehingga model dapat mempelajari kontribusi setiap fitur secara lebih seimbang. Rumus normalisasi yang digunakan adalah standard score sebagai berikut.

$$x_{norm} = \frac{(x - \mu)}{\sigma} \quad (5)$$

Keterangan:

x adalah nilai fitur asli.

μ adalah nilai rata rata fitur pada data latih.

σ adalah standar deviasi fitur pada data latih.

Parameter normalisasi dihitung hanya dari data *train*, kemudian diaplikasikan ke data uji untuk menjaga konsistensi dan menghindari kebocoran data (data leakage).

5. Ekstraksi Fitur

Ini merupakan jantung dari metodologi penelitian dimana karakteristik visual lesi serviks ditransformasi menjadi representasi numerik yang dapat diproses oleh algoritma *machine learning* untuk klasifikasi tingkat keparahan.

HSV Statistik

HSV statistik digunakan untuk menangkap karakteristik warna lesi serviks secara ringkas dan informatif. Citra RGB terlebih dahulu dikonversi ke ruang warna HSV (*Hue*, *Saturation*, *Value*) menggunakan OpenCV. Ruang warna ini dipilih karena mampu memisahkan informasi warna (*Hue*), tingkat kepekatan warna (*Saturation*), dan kecerahan (*Value*), sehingga lebih representatif untuk analisis citra medis dibandingkan ruang warna RGB standar. Hal ini sejalan dengan penelitian sebelumnya yang menunjukkan bahwa penggunaan ruang warna alternatif seperti HSV dapat meningkatkan performa klasifikasi citra serviks karena channel HSV lebih menonjolkan informasi warna dan pigmentasi yang relevan secara visual [2].


Untuk setiap channel HSV, dihitung dua parameter statistik, yaitu nilai rata-rata (*mean*) dan simpangan baku (*standard deviation*), sehingga dihasilkan total enam fitur HSV. Nilai mean menggambarkan kecenderungan warna dominan pada area lesi, sedangkan

standard deviation mencerminkan tingkat variasi warna dalam jaringan lesi. Fitur HSV statistik ini bersifat ringkas, mudah diinterpretasikan, dan efektif sebagai input model klasifikasi karena mampu merepresentasikan pola warna utama lesi tanpa menghasilkan dimensi fitur yang terlalu besar.


Color Dominant

1) KELAS: MILKY

Sampel: Case 185



Palet Warna Dominan




2) KELAS: OPAQUE


Sampel: Case 118



Palet Warna Dominan



3) KELAS: TRANSPARENT



Bagian color dominant menampilkan hasil ekstraksi warna dominan dari area ROI lesi menggunakan algoritma K-Means clustering dengan $k = 3$ pada ruang warna HSV. Setiap citra lesi dipisahkan menjadi tiga kelompok warna utama yang merepresentasikan warna paling sering muncul pada jaringan lesi. Diagram lingkaran menunjukkan proporsi kemunculan masing-masing warna dominan, sedangkan contoh citra memperlihatkan area lesi yang dianalisis tanpa memperhitungkan background hitam. Pada kelas Milky, warna dominan cenderung memiliki rona cerah dengan proporsi besar yang mencerminkan tampilan putih susu pada jaringan. Pada kelas Opaque, distribusi warna terlihat lebih merata dengan dominasi warna pucat dan keruh yang menunjukkan kepadatan jaringan lebih tinggi. Pada kelas Transparent, warna dominan didominasi gradasi merah muda terang dengan tingkat kecerahan tinggi, menandakan jaringan relatif homogen dan lebih transparan. Perbedaan proporsi dan karakter warna dominan ini menjadi fitur penting yang digunakan sistem untuk membedakan ketiga kelas lesi pada tahap klasifikasi.

Tambahan singkat yang mendukung alasan menggunakan fitur warna dominan. Studi Shinohara et al. 2023 menunjukkan bahwa perubahan warna setelah aplikasi asam asetat (*acetowhite*) adalah fitur visual penting yang membantu segmentasi lesi dan meningkatkan akurasi metode berbasis pembelajaran mesin untuk mendeteksi CIN [3].

Kombinasi Fitur untuk *Machine Learning*

Pada penelitian ini, model klasifikasi menggunakan total 15 fitur numerik sebagai input. Fitur-fitur tersebut terdiri dari 6 fitur statistik dari ruang warna HSV dan 9 fitur

berbasis warna dominan (*Dominant Color*) dari HSV. Alasan pemilihan fitur tersebut dijelaskan sebagai berikut:

1) Statistical HSV

Statistik deskriptif berupa nilai rata-rata dan simpangan baku pada setiap kanal Hue, Saturation, dan Value. Pendekatan ini dipilih karena menghasilkan representasi fitur yang lebih ringkas, mudah diinterpretasikan secara medis, dan tetap mampu menangkap karakteristik warna utama lesi serviks tanpa menghasilkan dimensi fitur yang terlalu besar.

Oleh karena itu, penelitian ini hanya mengambil tiga statistik deskriptif yang paling relevan dan representatif:

Fitur	Makna	Relevansi
H_std	Standard deviation kanal Hue	Menunjukkan tingkat variasi warna, membedakan lesi homogen vs heterogen.
H_mean	Rata-rata kanal Hue	Mewakili kecenderungan warna utama jaringan lesi.
S_mean	Rata-rata kanal Saturation	Untuk melihat seberapa pekat merah/putihnya.
S_std	Simpangan baku kanal Saturation	Menunjukkan variasi intensitas kejenuhan warna pada area lesi.
V_mean	Rata-rata kanal Value	Merepresentasikan tingkat kecerahan jaringan, berkaitan dengan refleksi acetowhite atau area gelap akibat vaskularisasi.
V_std	Simpangan Baku kanal Value	Menunjukkan variasi tingkat kecerahan. Berguna membedakan area lesi yang merata dan tidak merata.

2) Fitur Dominant Color (9 fitur)

Selain fitur HSV, digunakan juga fitur warna dominan berbasis K-Means clustering dengan $k = 3$. Setiap cluster merepresentasikan satu kelompok warna utama pada area lesi serviks di dalam ROI.

Pemilihan $k = 3$ didasarkan pada analisis grafik inertia. Nilai inertia turun tajam hingga $k = 3$ dan mulai melambat setelahnya. Pola ini menunjukkan bahwa tiga cluster sudah cukup untuk menangkap variasi warna utama pada lesi. Penambahan cluster di atas tiga tidak memberikan peningkatan informasi yang signifikan dan justru menambah kompleksitas fitur. Untuk setiap citra, diekstraksi total 9 fitur warna yang ringkas dan informatif, terdiri dari:

- Dom1_H, Dom1_S, Dom1_V : nilai Hue, Saturation, dan Value dari warna dominan pertama
- Dom2_H, Dom2_S, Dom2_V : nilai Hue, Saturation, dan Value dari warna dominan kedua
- Dom3_H, Dom3_S, Dom3_V : nilai Hue, Saturation, dan Value dari warna dominan ketiga

Dengan total 9 fitur, representasi warna tetap kuat secara klinis, mudah diinterpretasikan, dan efisien untuk digunakan sebagai input klasifikasi.

3) Feature Error Evaluation (HSV + Color Dominan)


Berdasarkan hasil evaluasi kesalahan fitur (feature error evaluation) menggunakan tiga pendekatan jarak yang berbeda, terlihat adanya trade-off antara nilai nominal error dan tingkat separabilitas kelas. Metode Euclidean menghasilkan nilai variansi intra-kelas (J1 dan J2) yang paling kecil secara nominal, namun metode ini memiliki kelemahan dalam kemampuan pemisahan antar-kelas (separability), di mana nilai tertingginya hanya mencapai 34,81% pada kelas Milky. Sebaliknya, metode Manhattan dan HSV Circular L1, meskipun menghasilkan nilai nominal error yang jauh lebih besar, justru menunjukkan kinerja yang lebih unggul dalam memisahkan klaster data, terbukti dengan peningkatan separability pada kelas Milky hingga mencapai kisaran 39%. Secara konsisten di seluruh metode, kelas Milky menjadi kelas yang paling mudah dikenali dengan tingkat separabilitas tertinggi dibandingkan kelas Opaque dan Transparent yang cenderung memiliki nilai separabilitas di bawah 30%, mengindikasikan bahwa fitur visual pada kelas Milky memiliki karakteristik

yang paling unik dan kompak, sementara kelas Opaque dan Transparent memiliki tingkat kemiripan fitur yang lebih tinggi sehingga lebih sulit dipisahkan.

Metode Jarak	Kelas	J1 (Image → Case)	J2 (Case → Class)	Separability (%)	J3 (Global Inter-Class)
Euclidean	Milky	23.49	49.05	34.81	26.19
	Opaque	37.44	68.91	27.54	
	Transparent	28.66	76.95	25.39	
Manhattan	Milky	52.28	105.63	38.93	67.34
	Opaque	86.99	162.97	29.24	
	Transparent	67.73	160.66	29.54	
HSV Circular L1	Milky	52.28	104.28	39.24	67.34
	Opaque	86.54	161.39	29.44	
	Transparent	67.43	159.90	29.64	

6. Machine Learning

XGBoost (eXtreme Gradient Boosting)



Implementasi utama menggunakan XGBoost, algoritma ensemble learning berbasis decision trees yang telah terbukti unggul dalam berbagai kompetisi *machine learning* dan aplikasi medis. XGBoost membangun banyak pohon keputusan (default 100 trees) secara sekuensial dimana setiap pohon baru mencoba memperbaiki kesalahan pohon sebelumnya melalui proses boosting. Parameter yang dikonfigurasi meliputi: `n_estimators=100` (jumlah pohon - lebih banyak meningkatkan akurasi tapi risiko overfitting), `learning_rate=0.1` (*shrinkage factor* yang membuat setiap pohon berkontribusi lebih konservatif untuk mencegah overfitting), `max_depth=5` (kedalaman maksimum pohon - mengontrol kompleksitas dan mencegah pohon terlalu spesifik ke training data), dan `objective='multi:softmax'` untuk klasifikasi multi-class dengan output langsung berupa predicted class.

XGBoost dipilih karena mampu menangani fitur numerik dengan baik, robust terhadap variasi data, serta efektif dalam memodelkan hubungan non-linear antar fitur warna. Karakteristik ini sesuai dengan sifat fitur HSV statistik dan warna dominan yang memiliki distribusi kompleks dan saling berinteraksi. Dalam konteks medis, XGBoost juga dapat menghasilkan probability estimates yang berguna untuk confidence scoring dalam diagnosis *assistive system* [4].

7. Evaluasi

Metrik evaluasi adalah alat untuk mengukur kualitas, performa, dan keberhasilan model. Dalam penelitian ini, metrik evaluasi yang digunakan untuk menilai model klasifikasi adalah *Confusion Matrix*. *Confusion Matrix* adalah tabel yang membandingkan hasil prediksi model dengan nilai aktual untuk melihat performa model klasifikasi. Tabel ini menunjukkan berapa banyak data yang diprediksi benar atau salah untuk setiap kelas. Dari *Confusion Matrix* bisa dihitung beberapa metrik penting untuk mengevaluasi model. Metrik yang dipakai dalam penelitian ini adalah *Accuracy* yang menunjukkan seberapa sering model memprediksi dengan benar, *Sensitivity* yang mengukur kemampuan model mengenali kelas positif, dan *Specificity* yang menunjukkan kemampuan model mengenali kelas negatif [5].

Model	Accuracy (%)	Specificity (%)			Sensitivity (%)		
		Milky	Opaque	Transparent	Milky	Opaque	Transparent
XGBoost	43	29	52	29	8	59	33

Accuracy

Metrik paling dasar yang menghitung proporsi prediksi yang benar dari total prediksi:

$$Accuracy = \frac{\sum_{i=1}^3 CM_{ii}}{\sum_{i=1}^3 \sum_{j=1}^3 CM_{ij}} \quad (6)$$

Menunjukkan akurasi untuk setiap model, dengan XGBoost umumnya mencapai performa tertinggi (sering di atas 80-90% tergantung kualitas dan variabilitas data lesi serviks). Dalam konteks kanker serviks, akurasi overall penting tapi harus diinterpretasikan hati-hati karena tidak membedakan jenis error - misalnya salah klasifikasi lesi severe sebagai mild jauh lebih berbahaya daripada sebaliknya.

Specificity

Mengukur kemampuan model dalam mengidentifikasi kelas negatif dengan benar. *Specificity* menunjukkan seberapa besar proporsi data negatif yang berhasil diprediksi sebagai negatif.

$$Specificity = \frac{\sum TN}{\sum TN + \sum FP} \quad (7)$$

Dalam konteks klasifikasi lesi serviks, *specificity* yang tinggi berarti model jarang salah mengklasifikasikan jaringan normal atau lesi ringan sebagai lesi berat. Hal ini penting untuk menghindari *false positive* yang dapat menyebabkan kepanikan pada pasien serta tindakan lanjutan yang tidak perlu, seperti pemeriksaan invasif. *Specificity* yang rendah menunjukkan bahwa model masih sering memberikan alarm palsu pada kelas negatif.

Sensitivity (Recall)


Mengukur seberapa banyak kasus *actual* dari suatu kelas yang berhasil terdeteksi:

$$Recall = \frac{TP}{TP + \sum FN} \quad (8)$$

Recall tinggi krusial terutama untuk kelas severe untuk tidak melewatkan kasus serius, memastikan semua lesi pre-kanker atau suspicious lesions terdeteksi dan mendapat follow-up yang tepat. Dalam screening kanker serviks, recall tinggi untuk lesi abnormal lebih diprioritaskan daripada precision, meskipun tetap perlu balance untuk menghindari terlalu banyak false positive yang membebani sistem kesehatan.

1) Confusion Matrix


Visualisasi heatmap dari confusion matrix menggunakan seaborn menunjukkan detail dimana model membuat kesalahan. Baris merepresentasikan true label (actual class dari lesi serviks berdasarkan gold standard diagnosis), kolom merepresentasikan predicted label. Diagonal menunjukkan correct classifications, off-diagonal menunjukkan misclassifications. Analisis confusion matrix sangat penting dalam aplikasi medis - misalnya jika banyak lesi "milky" (severe) misclassified sebagai "transparent" (mild), ini serious concern yang perlu investigasi lebih lanjut, mungkin karena feature extraction kurang sensitif terhadap subtle changes atau perlu incorporate additional features seperti tekstur atau pola vaskular. Sebaliknya, misclassification dari mild ke severe, meskipun menyebabkan overtreatment, lebih acceptable dari perspektif patient safety. Confusion matrix dengan XGBoost biasanya menunjukkan konsentrasi kuat di diagonal dengan relatively sedikit misclassifications, mengkonfirmasi bahwa fitur warna yang diekstraksi memang diskriminatif untuk membedakan tingkat keparahan lesi serviks.



Berdasarkan analisis *Final Confusion Matrix*, model menunjukkan kinerja yang tidak seimbang dengan dominasi prediksi yang kuat pada kelas **Opaque**, di mana 27 data berhasil diklasifikasikan dengan benar. Sebaliknya, kemampuan model dalam mengenali kelas **Milky** dan **Transparent** masih rendah, yang ditandai dengan tingginya tingkat kesalahan klasifikasi (*misclassification*) di mana 12 sampel Milky dan 9 sampel Transparent secara keliru diprediksi sebagai Opaque. Hal ini mengindikasikan adanya bias model terhadap fitur kelas Opaque yang mendominasi, sehingga menyebabkan rendahnya sensitivitas dan akurasi pada kedua kelas lainnya yang sering kali gagal dibedakan dari karakteristik Opaque.

8. Analisis Hasil Eksperimen

1) Distribusi Hue per Kelas



Kelas Milky

Distribusi Hue pada kelas Milky menunjukkan sebaran yang relatif luas dengan beberapa puncak (multi-modal). Nilai Hue terkonsentrasi pada rentang rendah (mendekati 0°) serta pada rentang menengah hingga tinggi (sekitar 90° – 150° dan $>300^\circ$). Pola ini mengindikasikan bahwa lesi Milky memiliki variasi warna yang cukup tinggi, mulai dari putih susu hingga gradasi warna lain yang lebih kompleks. Variasi ini selaras dengan karakteristik klinis lesi Milky yang sering menampilkan pola warna tidak homogen (mosaicism), sehingga meningkatkan nilai H_std pada kelas ini.

Kelas Opaque

Pada kelas Opaque, distribusi Hue menunjukkan konsentrasi yang kuat pada rentang Hue rendah (sekitar 0° – 30°), dengan tambahan sebaran pada rentang menengah. Dominasi Hue rendah mengindikasikan keberadaan warna putih pekat atau keabuan yang konsisten, mencerminkan jaringan lesi yang lebih padat dan kurang transparan. Distribusi yang relatif lebih terpusat ini menjelaskan mengapa model cenderung lebih mudah mengenali kelas Opaque dibandingkan kelas lainnya.

Kelas Transparent

Distribusi Hue pada kelas Transparent menunjukkan pola yang lebih terkonsentrasi dibandingkan Milky, namun dengan rentang Hue yang cenderung berada pada nilai rendah hingga menengah. Dominasi warna terang dengan variasi Hue yang lebih terbatas menunjukkan karakteristik jaringan yang relatif homogen dan terang. Pola ini sesuai dengan ciri visual lesi Transparent yang umumnya memiliki refleksi cahaya lebih tinggi dan kejenuhan warna yang lebih rendah.


Perbandingan Antar Kelas

Secara keseluruhan, terlihat adanya tumpang tindih distribusi Hue antara kelas Milky dan Transparent, khususnya pada rentang Hue rendah hingga menengah. Tumpang tindih ini menjadi salah satu penyebab kesalahan klasifikasi yang diamati pada evaluasi model, di mana beberapa sampel Milky atau Transparent diprediksi sebagai Opaque. Sebaliknya, distribusi Hue kelas Opaque yang lebih terpusat dan konsisten memberikan sinyal warna yang lebih kuat bagi model.

Analisis ini menunjukkan bahwa meskipun fitur Hue efektif untuk menangkap perbedaan karakteristik warna antar kelas, penggunaan Hue saja belum sepenuhnya cukup untuk memisahkan kelas dengan perbedaan visual yang subtil. Oleh karena itu, penggabungan Hue dengan fitur Saturation, Value, serta warna dominan menjadi langkah penting untuk meningkatkan diskriminasi antar kelas lesi.

2) Analisis Distribusi Fitur HSV Antar Kelas

Visualisasi hubungan antar komponen HSV dilakukan menggunakan scatter plot Hue–Saturation, Hue–Value, dan Saturation–Value untuk masing-masing kelas Milky, Opaque, dan Transparent. Analisis ini bertujuan untuk mengidentifikasi pola sebaran fitur warna serta tingkat tumpang tindih antar kelas.



Kelas Milky

Pada kelas Milky, plot **Hue vs Saturation** menunjukkan dua kecenderungan utama: sebagian besar titik terkonsentrasi pada nilai Saturation tinggi dengan Hue pada rentang menengah, sementara sebagian lainnya tersebar pada Saturation rendah dengan Hue yang lebih beragam. Pola ini mengindikasikan adanya variasi warna yang cukup besar dalam kelas Milky.

Plot **Hue vs Value** memperlihatkan dominasi nilai Value yang tinggi, meskipun terdapat beberapa titik dengan Value rendah. Hal ini menunjukkan bahwa lesi Milky umumnya tampak terang, tetapi masih memiliki variasi intensitas pencahayaan.

Pada plot **Saturation vs Value**, sebagian besar titik berada pada area Value tinggi dengan variasi Saturation yang cukup lebar. Pola ini mencerminkan karakteristik lesi Milky yang relatif terang namun tidak selalu memiliki kejenuhan warna yang seragam.

Kelas Opaque

Distribusi pada kelas Opaque menunjukkan pola yang lebih terstruktur. Pada plot **Hue vs Saturation**, terlihat konsentrasi titik pada Saturation tinggi dengan Hue yang relatif sempit. Hal ini mengindikasikan warna yang lebih pekat dan konsisten dibandingkan kelas lainnya.

Plot **Hue vs Value** memperlihatkan sebagian besar titik berada pada Value tinggi, namun dengan sebaran Hue yang lebih terkontrol. Dibandingkan Milky, kelas Opaque memiliki variasi warna yang lebih rendah, yang menjelaskan mengapa model cenderung lebih stabil dalam mengenali kelas ini.

Pada plot **Saturation vs Value**, titik-titik terkonsentrasi pada area Saturation dan Value yang tinggi, menunjukkan jaringan lesi yang pekat dan terang secara konsisten. Pola ini menjadi ciri visual kuat yang memudahkan model dalam membedakan kelas Opaque.

Kelas Transparent

Kelas Transparent menunjukkan distribusi yang lebih homogen. Pada plot **Hue vs Saturation**, sebagian besar titik berada pada Saturation sedang hingga rendah dengan Hue yang tersebar, menandakan kejenuhan warna yang relatif rendah.

Plot **Hue vs Value** memperlihatkan dominasi Value tinggi dengan variasi Hue yang cukup besar. Hal ini menunjukkan bahwa lesi Transparent umumnya memiliki kecerahan tinggi namun warna yang lebih pucat.

Pada plot **Saturation vs Value**, titik-titik terkonsentrasi pada Value tinggi dan Saturation rendah hingga sedang. Pola ini mencerminkan karakteristik jaringan yang terang dan kurang pekat, sesuai dengan sifat visual kelas Transparent.

Perbandingan Antar Kelas

Secara keseluruhan, terlihat adanya tumpang tindih distribusi fitur HSV antara kelas Milky dan Transparent, terutama pada kombinasi Value tinggi dan Saturation rendah hingga sedang. Tumpang tindih ini menjelaskan kesalahan klasifikasi yang terjadi pada model, di mana beberapa sampel Milky atau Transparent diprediksi sebagai Opaque atau saling tertukar.

Sebaliknya, kelas **Opaque** menunjukkan pola sebaran yang lebih terkonsentrasi dan konsisten, khususnya pada Saturation dan Value yang tinggi. Hal ini menyebabkan model cenderung lebih mudah mengenali kelas Opaque dibandingkan dua kelas lainnya.

Analisis ini menegaskan bahwa meskipun fitur HSV efektif dalam menangkap karakteristik warna utama lesi, perbedaan antar kelas yang bersifat subtil masih sulit dipisahkan sepenuhnya hanya dengan fitur warna. Oleh karena itu, kombinasi fitur HSV statistik dan warna dominan menjadi penting untuk meningkatkan daya diskriminasi model.

3) Analisis Hasil Prediksi

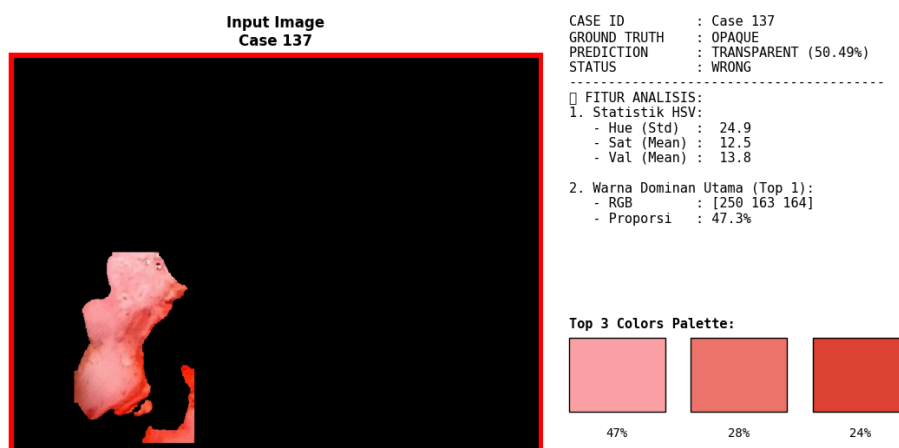


Gambar di atas menunjukkan contoh hasil prediksi model pada Case 098. Citra masukan merupakan area lesi hasil segmentasi, di mana background telah dihilangkan sehingga analisis hanya berfokus pada jaringan lesi serviks. Berdasarkan *ground truth*, citra ini termasuk dalam kelas Opaque, dan model XGBoost berhasil memprediksi kelas yang sama dengan tingkat kepercayaan sebesar 75,82%, menunjukkan prediksi yang sesuai.

Keputusan model dipengaruhi oleh kombinasi fitur statistik HSV dan fitur warna dominan. Dari sisi HSV statistik, nilai Hue mean sebesar 55,4 menunjukkan kecenderungan warna pada rentang kemerahan–pink, yang umum ditemukan pada jaringan lesi dengan densitas tinggi. Nilai Saturation mean sebesar 19,6 mengindikasikan kejenuhan warna yang relatif rendah hingga sedang, sedangkan Value mean sebesar 28,3 menunjukkan tingkat kecerahan yang tidak terlalu tinggi. Kombinasi ini mencerminkan karakteristik visual jaringan yang tampak lebih padat dan tidak transparan.

Analisis warna dominan juga memperkuat hasil prediksi. Warna dominan utama memiliki nilai RGB [214, 141, 185] dengan proporsi sekitar 55,6%, menunjukkan bahwa lebih dari setengah area lesi didominasi oleh satu warna utama. Palet warna yang dihasilkan memperlihatkan dominasi warna pink keunguan yang relatif pekat, dengan variasi warna lain dalam proporsi yang lebih kecil. Pola ini sejalan dengan karakteristik kelas **Opaque** yang cenderung memiliki warna dominan yang kuat dan konsisten.

Berdasarkan analisis tersebut, model mengasosiasikan kombinasi warna dominan yang jelas, variasi warna yang relatif terbatas, serta tingkat kecerahan yang tidak terlalu tinggi sebagai ciri khas kelas **Opaque**. Contoh ini menunjukkan bahwa model mampu memanfaatkan fitur warna secara efektif untuk menghasilkan prediksi yang sesuai dengan label sebenarnya, khususnya pada kasus dengan karakteristik visual yang cukup jelas



Gambar di atas menunjukkan hasil prediksi model pada **Case 137**. Berdasarkan label *ground truth*, citra ini termasuk dalam kelas **Opaque**, namun model XGBoost memprediksi

kelas Transparent dengan tingkat keyakinan sebesar 50,49%, sehingga dikategorikan sebagai prediksi yang tidak sesuai.

Dari sisi fitur statistik HSV, nilai H_std sebesar 24,9 menunjukkan variasi warna yang relatif sedang, tidak terlalu tinggi seperti pada lesi dengan pola mosaicism. Nilai S_mean sebesar 12,5 mengindikasikan kejenuhan warna yang rendah, sementara V_mean sebesar 13,8 menunjukkan tingkat kecerahan yang juga rendah. Kombinasi kejenuhan rendah dan kecerahan yang tidak terlalu tinggi menyebabkan karakteristik warna lesi tampak pucat dan kurang pekat.

Analisis warna dominan memperlihatkan bahwa warna dominan utama memiliki nilai RGB [250, 163, 164] dengan proporsi sekitar 47,3%. Warna ini tergolong terang dengan dominasi gradasi merah muda pucat. Palet warna yang dihasilkan didominasi oleh warna-warna cerah dengan perbedaan intensitas yang relatif kecil antar warna dominan.

Berdasarkan pola tersebut, model cenderung mengasosiasikan kombinasi kejenuhan rendah dan warna dominan yang cerah sebagai karakteristik kelas Transparent. Hal ini menyebabkan pergeseran prediksi meskipun secara klinis citra tersebut termasuk dalam kelas Opaque. Kasus ini menunjukkan bahwa ketika perbedaan visual antar kelas menjadi subtil, terutama pada aspek kejenuhan dan kecerahan warna, model berbasis fitur warna memiliki keterbatasan dalam membedakan kelas secara akurat.

Analisis ini mengindikasikan bahwa kesalahan klasifikasi terutama terjadi pada citra dengan karakteristik warna yang berada pada area peralihan antar kelas. Dengan demikian, meskipun fitur HSV dan warna dominan efektif dalam banyak kasus, terdapat kebutuhan akan fitur tambahan atau pendekatan lanjutan untuk meningkatkan ketahanan model terhadap kasus-kasus ambigu.

REFERENSI

- [1] Dong, L., & Kang, M. (2025). Quantitative Comparison of Geographical Color of Traditional Village Architectural Heritage Based on K-Means Color Clustering—A Case Study of Southeastern Hubei Province, China. *Buildings*, 15(5). <https://doi.org/10.3390/buildings15050748>

- [2] I. Jiménez-López et al., “Color Space Comparison of Isolated Cervix Cells for Classification: Impact of HSV Among Others,” preprint, 2025.
- [3] T. Shinohara, K. Murakami, dan N. Matsumura, "Diagnosis Assistance in Colposcopy by Segmenting Acetowhite Epithelium Using U-Net with Images before and after Acetic Acid Solution Application," *Diagnostics*, vol. 13, no. 9, art. 1596, Apr. 29, 2023. doi: 10.3390/diagnostics13091596.
- [4] M. Babayomi, O. A. Olagbaju, dan A. A. Kadiri, “Convolutional XGBoost (C-XGBOOST) Model for Brain Tumor Detection,” arXiv preprint arXiv:2301.02317, Jan. 2023.
- [5] O. Rainio, “Evaluation metrics and statistical tests for machine learning,” *Sci. Rep.*, pp.1–14, 2024, doi: 10.1038/s41598-024-56706-x.